

1. *Back to the Future.*

- (a) ■ Primero se debe construir el lado derecho de la ecuación, es decir, el vector \mathbf{w} . Para asegurar una mejor aproximación, es decir, con la menor cota superior del error en el intervalo, se utilizará el conjunto S_2 de los puntos de Chebyshev: \mathbf{x}^c e \mathbf{y}^c . Entonces,
- (i) [5 puntos]: se construye un polinomio interpolador $p_{m-1}(x)$ utilizando Interpolación Baricéntrica para reducir la cantidad de operaciones elementales en su evaluación. La interpolación polinomial se realizará con \mathbf{x}^c e \mathbf{y}^c , es decir con los puntos de Chebyshev disponibles. Esta elección se hace para reducir el fenómeno de Runge. La interpolación polinomial asegura que $p_{m-1}(x_k^c) = y_k^c$, para así posteriormente aproximar $f(x_j)$ con $p_{m-1}(x_j)$, es decir,
- (ii) [5 puntos]: se evalúan los n puntos $x_j = \frac{2}{n-1}(j-1)-1$ en $p_{m-1}(x_j)$ para $j = \{1, \dots, n\}$. Notar que el vector \mathbf{w} se define como $[f(x_1), f(x_2), \dots, f(x_j), \dots, f(x_n)]^T$ sin embargo se aproximará con $[p_{m-1}(x_1), p_{m-1}(x_2), \dots, p_{m-1}(x_j), \dots, p_{m-1}(x_n)]^T$
- [10 puntos]: Segundo, se debe resolver la ecuación, $T_n \mathbf{v} = \mathbf{w}$, para encontrar el vector condensador. Tomamos ventaja de la forma de la matriz T_n , ya que está factorizada en dos matrices triangulares, es decir, conocemos la factorización LU de T_n . Entonces realmente tenemos $L_n U_n \mathbf{v} = \mathbf{w}$, (i) definimos el vector auxiliar $\mathbf{z} = U_n \mathbf{v}$, lo cual genera $L_n U_n \mathbf{v} = L_n \mathbf{z} = \mathbf{w}$. Es decir debemos resolver el sistema de ecuaciones lineales $L_n \mathbf{z} = \mathbf{w}$ y dado que tiene una estructura bidiagonal-“triangular inferior”, podemos obtener \mathbf{z} utilizando una versión reducida de *forward substitution* para tomar ventaja de la estructura presentada y (ii) luego de obtener \mathbf{z} , podemos obtener \mathbf{v} resolviendo el sistema de ecuaciones lineales bidiagonal-“triangular superior” $U_n \mathbf{v} = \mathbf{z}$ utilizando una versión reducida de *backward substitution* para tomar ventaja de la estructura presentada.
- Para resolver $L_n \mathbf{z} = \mathbf{w}$, mediante una versión reducida de *forward substitution*, debemos realizar los siguientes pasos para tomar ventaja de la estructura de L_n y obtener \mathbf{z} :
- 1ra ecuación: $z_1 = w_1$, la cual entrega el valor de z_1 directamente, es decir $z_1 = w_1$.
 - 2da ecuación: $-\frac{1}{2}z_1 + z_2 = w_2$, despejando z_2 obtenemos $z_2 = w_2 + \frac{1}{2}z_1$. Recordar que en este paso ya conocemos el valor de z_1 .
 - i -ésima ecuación: $-\frac{(i-1)}{i}z_{i-1} + z_i = w_i$, despejando z_i se obtiene $z_i = w_i + \frac{(i-1)}{i}z_{i-1}$ para $i = \{3, \dots, n-1\}$.
 - n -ésima ecuación: $-\frac{(n-1)}{n}z_{n-1} + z_n = w_n$, finalmente despejando z_n se obtiene $z_n = w_n + \frac{(n-1)}{n}z_{n-1}$.
- [10 puntos]: Por otro lado, para resolver $U_n \mathbf{v} = \mathbf{z}$, mediante una versión reducida de *backward substitution*, debemos realizar los siguientes pasos para tomar ventaja de la estructura de U_n y obtener \mathbf{v} :
- n -ésima ecuación: $\frac{n+1}{n}v_n = z_n$, por lo tanto despejando v_n obtenemos $v_n = \frac{n}{n+1}z_n$.
 - $(n-1)$ -ésima ecuación: $\frac{n}{n-1}v_{n-1} - v_n = z_n$, despejando v_{n-1} obtenemos $v_{n-1} = \frac{n-1}{n}(z_n + v_n)$.
 - i -ésima ecuación: $\frac{i+1}{i}v_i - v_{i+1} = z_i$, despejando v_i obtenemos $v_i = \frac{i}{i+1}(z_i + v_{i+1})$ para $i = \{2, \dots, n-2\}$.
 - 1ra ecuación: $2v_1 - v_2 = z_1$, despejando v_1 obtenemos $v_1 = \frac{1}{2}(z_1 + v_2)$.

Por lo tanto se puede obtener \mathbf{v} primero interpolando la *data* disponibles en los puntos de Chebyshev con interpolación Baricéntrica y luego resolviendo la secuencia de sistemas de ecuaciones lineales generados por L_n y U_n respectivamente, tomando ventaja de las definiciones de L_n y U_n entregadas.

```

(b) '''
input:
n : (integer) dimension of the matrix T_n.
output:
v : (ndarray) array of dimension n that stores the estimation of capacitor vector "v".
'''
def capacitor_vector(n):
    % Loading m-dimensional vector data  $\mathbf{x}^e$  and  $\mathbf{y}^e$ 
    xe = np.load('/ScientificComputing/DrEmmettData_xe.npz')
    ye = np.load('/ScientificComputing/DrEmmettData_ye.npz')
    % Loading m-dimensional vector data  $\mathbf{x}^c$  and  $\mathbf{y}^c$ 
    xc = np.load('/ScientificComputing/DrEmmettData_xc.npz')
    yc = np.load('/ScientificComputing/DrEmmettData_yc.npz')
    % Hint: You should only use one pair of vectors

    ■ [5 puntos] Obtener el vector  $\mathbf{w}$  mediante interpolación Baricéntrica
    j = np.arange(1,n + 1)
    xj = (2*(j - 1))/(n - 1) - 1.
    pB = BarycentricInterpolation(xc,yc)
    w = pB(xj)

    ■ [10 puntos] Resolver el sistema de ecuaciones  $L_n \mathbf{z} = \mathbf{w}$ 
    z = np.ones((n,1)) # or better "z = np.ones(n)"
    z[0] = w[0]
    for i in np.arange(2,n + 1):
        z[i - 1] = w[i - 1] + (i - 1)*z[i - 2]/(i)

    ■ [10 puntos] Resolver el sistema de ecuaciones  $U_n \mathbf{v} = \mathbf{z}$ 
    v = np.ones((n,1)) # or better "v = np.ones(n)"
    v[n-1] = (n*z[n - 1])/(n + 1)
    for i in np.arange(n - 1,0,-1):
        v[i-1] = (i*(z[i-1] + v[i]))/(i + 1)
    return v

```

2. Ambigüedad espacial.

- (a) ■ **[10 puntos]:** La primera tarea es construir la aproximación paramétrica:

$$\mathbf{r}(t) = \langle f_1(t), f_2(t) \rangle = \langle a_1 + b_1 t, a_2 + b_2 t \rangle$$

Esto significa que debemos obtener los valores de a_1, b_1, a_2 y b_2 . Para esto, debemos resolver **dos** problemas de mínimos cuadrados: aproximar $f_1(t)$ que tiene relación con las coordenadas x_k de las mediciones y aproximar $f_2(t)$ que tiene relación con las coordenadas y_k de las mediciones. Entonces debemos resolver los siguientes sistemas de ecuaciones $A \mathbf{c}_1 = \mathbf{x}_k$ y $A \mathbf{c}_2 = \mathbf{y}_k$, donde los lados derechos \mathbf{x}_k y \mathbf{y}_k corresponden a las coordenadas x_k e y_k y los vectores \mathbf{c}_1 y \mathbf{c}_2 corresponden a los coeficientes $[a_1, b_1]^T$ y $[a_2, b_2]^T$, respectivamente:

$$\begin{array}{rcll} a_1 + b_1 t_1 & = & x_1 & \\ a_1 + b_1 t_2 & = & x_2 & \\ a_1 + b_1 t_3 & = & x_3 & \\ \vdots & \vdots & \vdots & \\ a_1 + b_1 t_{n-2} & = & x_{n-2} & \\ a_1 + b_1 t_{n-1} & = & x_{n-1} & \\ a_1 + b_1 t_n & = & x_n & \end{array} \Rightarrow \begin{bmatrix} 1 & t_1 \\ 1 & t_2 \\ 1 & t_3 \\ \vdots & \vdots \\ 1 & t_{n-2} \\ 1 & t_{n-1} \\ 1 & t_n \end{bmatrix} \begin{bmatrix} a_1 \\ b_1 \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_{n-2} \\ x_{n-1} \\ x_n \end{bmatrix} \Rightarrow A \mathbf{c}_1 = \mathbf{x}_k$$

$$\begin{array}{rcll} a_2 + b_2 t_1 & = & y_1 & \\ a_2 + b_2 t_2 & = & y_2 & \\ a_2 + b_2 t_3 & = & y_3 & \\ \vdots & \vdots & \vdots & \\ a_2 + b_2 t_{n-2} & = & y_{n-2} & \\ a_2 + b_2 t_{n-1} & = & y_{n-1} & \\ a_2 + b_2 t_n & = & y_n & \end{array} \Rightarrow \begin{bmatrix} 1 & t_1 \\ 1 & t_2 \\ 1 & t_3 \\ \vdots & \vdots \\ 1 & t_{n-2} \\ 1 & t_{n-1} \\ 1 & t_n \end{bmatrix} \begin{bmatrix} a_2 \\ b_2 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_{n-2} \\ y_{n-1} \\ y_n \end{bmatrix} \Rightarrow A \mathbf{c}_2 = \mathbf{y}_k$$

Notar que la matriz A asociada a ambos sistemas de ecuaciones lineales sobre-determinados es la misma, dado que se tiene los datos en el mismo tiempo.

- **[5 puntos]:** Luego de construido el sistema de ecuaciones lineales sobre-determinado, se puede encontrar los coeficientes que minimizan el error cuadrático de la matriz A , es decir $A = \hat{Q} \hat{R}$, de la siguiente forma:

$$\bar{\mathbf{c}}_1 = \begin{bmatrix} \bar{a}_1 \\ \bar{b}_1 \end{bmatrix} = \hat{R}^{-1} \hat{Q}^* \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad \text{y} \quad \bar{\mathbf{c}}_2 = \begin{bmatrix} \bar{a}_2 \\ \bar{b}_2 \end{bmatrix} = \hat{R}^{-1} \hat{Q}^* \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}.$$

Notar que \hat{R}^{-1} -por-un-vector nos indica que debemos resolver el sistema de ecuaciones lineales asociado, en particular acá se puede utilizar *backward substitution*. También es posible haber usado las ecuaciones normales.

- **[10 puntos]:** Una vez construida las parametrizaciones solicitadas podemos minimizar la función $g(t)$, la cual la definimos ahora con los parámetros obtenidos, es decir,

$$g(t) = (p_x - \bar{a}_1 - \bar{b}_1 t)^2 + (p_y - \bar{a}_2 - \bar{b}_2 t)^2.$$

Para encontrar el mínimo, podemos obtener la derivada,

$$\begin{aligned} g'(t) &= 2 (p_x - \bar{a}_1 - \bar{b}_1 t) (-\bar{b}_1) + 2 (p_y - \bar{a}_2 - \bar{b}_2 t) (-\bar{b}_2), \\ &= -2 (p_x \bar{b}_1 - \bar{a}_1 \bar{b}_1 - \bar{b}_1^2 t) - 2 (p_y \bar{b}_2 - \bar{a}_2 \bar{b}_2 - \bar{b}_2^2 t) \\ &= -2 (p_x \bar{b}_1 - \bar{a}_1 \bar{b}_1 - \bar{b}_1^2 t + p_y \bar{b}_2 - \bar{a}_2 \bar{b}_2 - \bar{b}_2^2 t) \end{aligned}$$

simplificando e igualando a 0 obtenemos,

$$\begin{aligned} (p_x \bar{b}_1 - \bar{a}_1 \bar{b}_1 - \bar{b}_1^2 t + p_y \bar{b}_2 - \bar{a}_2 \bar{b}_2 - \bar{b}_2^2 t) &= 0, \\ (\bar{b}_1^2 + \bar{b}_2^2) \tilde{t} &= (p_x \bar{b}_1 - \bar{a}_1 \bar{b}_1 + p_y \bar{b}_2 - \bar{a}_2 \bar{b}_2) \\ \tilde{t} &= \frac{(p_x \bar{b}_1 - \bar{a}_1 \bar{b}_1 + p_y \bar{b}_2 - \bar{a}_2 \bar{b}_2)}{\bar{b}_1^2 + \bar{b}_2^2}. \end{aligned}$$

- **[5 puntos]:** Por lo tanto la distancia mínima es $\sqrt{g(\tilde{t})}$.

(b) '''

input:

p : (ndarray) 2-dimensional point p.
xk : (ndarray) array of dimension "n" that stores the "x_k" measurements.
yk : (ndarray) array of dimension "n" that stores the "y_k" measurements.
tk : (ndarray) array of dimension "n" that stores the "t_k" measurements.
n : (integer) Number of measurements.

output:

d : (float) minimal distance from point p to the parametric representation of street C.
'''

def map_matching(p,xk,yk,tk,n):

- [5 puntos]: construir la matriz A para los problemas de mínimos cuadrados asociado y obtener su factorización QR reducida.

A = np.ones((n,2))

A[:,1] = tk

Q,R = np.linalg.qr(A,mode="reduced")

- [10 puntos]: resolver el problema de mínimos cuadrados $A \mathbf{c}_1 = \mathbf{x}_k$ y $A \mathbf{c}_2 = \mathbf{y}_k$

c1 = np.dot(np.transpose(Q),xk)

a1,b1 = np.linalg.solve(R,c1)

c2 = np.dot(np.transpose(Q),yk)

a2,b2 = np.linalg.solve(R,c2)

- [5 puntos]: calcular \tilde{t} donde la distancia es mínima

t_tilde = (p[0]*b1 - a1*b1 + p[1]*b2 - a2*b2)/(b1**2 + b2**2)

- [5 puntos]: calcular la distancia mínima

xt_tilde = a1 + b1*t_tilde

yt_tilde = a2 + b2*t_tilde

d = np.linalg.norm(p - np.array([xt_tilde,yt_tilde]))

return d