

1. Desarrollo Pregunta 1:

- (a) [5 puntos] Primero se debe aproximar el valor absoluto de la derivada de $f(x)$ para así obtener los puntos $z_k \approx |f'(x_k)|$ con alguna regla de aproximación. Por ejemplo, se puede aplicar **forward-difference** para aproximar la derivada en cada punto x_k para $k \in \{0, 1, \dots, n\}$:

$$z_k = \frac{|y_{k+1} - y_k|}{x_{k+1} - x_k} \quad \text{para } k \in \{0, 1, \dots, n\}$$

Segundo, nos falta la derivada para el punto x_{n+1} , en este caso utilizamos **backward-difference** para la aproximación:

$$z_{n+1} = \frac{|y_{n+1} - y_n|}{x_{n+1} - x_n}$$

Notar que el valor absoluto se aplica solo al numerador de z_k porque se conoce que el denominador es siempre positivo. [10 puntos] Finalmente, utilizando los puntos z_k para $k \in \{0, 1, \dots, n+1\}$ obtenidos, se aplica el método del Trapecio, pero una versión modificada, ya que la data no está equiespaciada. Para cada intervalo $[x_k, x_{k+1}]$ con $k \in \{0, \dots, n\}$ se aproxima la integral como:

$$\int_{x_k}^{x_{k+1}} |f'(x)| \approx \frac{(z_k + z_{k+1})(x_{k+1} - x_k)}{2} = (z_k + z_{k+1}) \frac{\Delta x_k}{2}$$

donde $\Delta x_k = (x_{k+1} - x_k)$. Aplicando en todo el intervalo para $|f'(x)|$ se tiene que:

$$\begin{aligned} \int_{-1}^1 |f'(x)| &\approx \sum_{k=0}^n (z_k + z_{k+1}) \frac{\Delta x_k}{2} \\ &\approx (z_0 + z_1) \frac{\Delta x_0}{2} + (z_1 + z_2) \frac{\Delta x_1}{2} + \dots + (z_n + z_{n+1}) \frac{\Delta x_n}{2} \\ &\approx \frac{\Delta x_0}{2} z_0 + \left(\frac{\Delta x_0}{2} + \frac{\Delta x_1}{2} \right) z_1 + \left(\frac{\Delta x_1}{2} + \frac{\Delta x_2}{2} \right) z_2 + \left(\frac{\Delta x_{n-1}}{2} + \frac{\Delta x_n}{2} \right) z_n + \frac{\Delta x_n}{2} z_{n+1} \\ &\approx \frac{\Delta x_0}{2} z_0 + \frac{\Delta x_n}{2} z_{n+1} + \sum_{k=0}^{n-1} \left(\frac{\Delta x_k}{2} + \frac{\Delta x_{k+1}}{2} \right) z_{k+1} \end{aligned}$$

Notar que si $h = \Delta x_0 = \Delta x_1 = \dots = \Delta x_n$ obtenemos los pesos del método del Trapecio para puntos equiespaciados.

- (b) Se debe evaluar un punto x_j en la ecuación diferencial, por lo tanto, se debe obtener $f''(x_j)$, $f'(x_j)$ y $f(x_j)$.
- [5 puntos] Para un punto x_j se puede utilizar la función AGSD(\cdot) para aproximar $f''(x_j)$. Se debe entregar a la función los parámetros adecuados:

$$f''(x_j) \approx \text{AGSD}(x_{j-1}, y_{j-1}, x_j, y_j, x_{j+1}, y_{j+1})$$

- [5 puntos] Para la derivada $f'(x_j)$ se utiliza la aproximación realizada en el ítem anterior $f'(x_j) \approx (y_{j+1} - y_j)/(x_{j+1} - x_j)$ y para evaluar la función en x_j , es decir, $f(x_j)$, simplemente se utiliza los datos disponibles, por lo tanto, $f(x_j) = y_j$
- [5 puntos] Finalmente se evalúa si el punto x_j aproxima la ecuación diferencial con una tolerancia δ :

$$\left| \alpha \text{AGSD}(x_{j-1}, y_{j-1}, x_j, y_j, x_{j+1}, y_{j+1}) + \beta \frac{(y_{j+1} - y_j)}{(x_{j+1} - x_j)} + \gamma y_j - 1 \right| < \delta$$

(c) '''

```
input:
n          : (integer) Value of n, where the length of the sequence in the table is n + 2.
x_k        : (ndarray) Array with the values of x_k.
y_k        : (ndarray) Array with the values of y_k.
alpha      : (float) Value of alpha.
beta       : (float) Value of beta.
gamma      : (float) Value of gamma.
j          : (integer) Index where the differential equation is verified for the data.
delta      : (float) Tolerance.

output:
total_var  : (float) Approximation of total variation of f(x).
check      : (bool) Boolean value that indicates if the data approximates the differential
equation at x_j. If the data satisfied the tolerance, the output must be True, otherwise False.
'''

def jones(n,x_k,y_k,alpha,beta,gamma,j,delta):
    ■ [4 puntos] Calcular  $y_{k+1} - y_k$  y  $x_{k+1} - x_k$  para  $k \in \{0, 1, \dots, n\}$ 
    delta_y = np.diff(y_k)
    delta_x = np.diff(x_k)

    ■ [6 puntos] Aproximación del valor absoluto de la derivada en  $x_k$  para  $k \in \{0, 1, \dots, n + 1\}$ 
    z = np.zeros(n + 2)
    z[:n+1] = np.abs(delta_y) / delta_x
    % using backward difference for the last node
    z[n+1] = np.abs(y_k[n+1] - y_k[n])/delta_x[n]

    ■ [8 puntos] Utilizar los pesos modificados y calcular la aproximación de la integral mediante el producto punto.
    w = np.zeros(n+2)
    w[0] = delta_x[0] / 2
    w[-1] = delta_x[-1] / 2
    w[1:-1] = (delta_x[:n] + delta_x[1:]) / 2
    total_var = np.dot(w,z)

    ■ [5 puntos] Evaluar la ecuación diferencial en el punto  $x_j$ 
    yp = delta_y[j] / delta_x[j]
    ode = alpha*AGSD(x_k[j-1],y_k[j-1],x_k[j],y_k[j],x_k[j+1],y_k[j+1]) + beta*yp + gamma*y_k[j]

    ■ [2 puntos] Verificar si en el punto  $x_j$ , la data aproxima la ecuación diferencial entregada,
    check = np.abs(ode - 1) < delta
    return total_var,check
```

2. Desarrollo Pregunta 2:

- (a) ■ **[12 puntos]** Dado que no tenemos acceso a la matriz A de forma explícita, es decir no está almacenada en memoria (sea RAM o disco o cualquier medio de almacenamiento), no podemos operar directamente con ella. Esto significa que no es posible hacer operaciones filas o columnas sobre ella. Lo que sí sabemos es que la matriz A se define como la suma de 2 matrices, la matriz B_1 y B_2 , donde la matriz B_1 es *sparse* y sí está almacenada en memoria de forma explícita pero la matriz B_2 no. Para operar con la matrix B_2 tenemos acceso a la función $\text{SFP}(\mathbf{v})$, que dado un vector \mathbf{v} entrega el producto entre B_2 y \mathbf{v} . Entonces, para poder obtener el producto entre A y un vector arbitrario \mathbf{v} lo podemos construir de la siguiente forma:

$$\begin{aligned} A\mathbf{v} &= (B_1 + B_2)\mathbf{v} \\ &= B_1\mathbf{v} + B_2\mathbf{v} \\ &= B_1\mathbf{v} + \text{SFP}(\mathbf{v}), \end{aligned}$$

donde A , B_1 y B_2 pertenecen a $\mathbb{R}^{n \times n}$, y $\mathbf{v} \in \mathbb{R}^n$. Lo que implica que tenemos a nuestra disposición el operador $A\mathbf{v}$, es decir el producto entre A y el vector \mathbf{v} por medio de B_1 y $\text{SFP}(\cdot)$. Con estos antecedentes a nuestra disposición y dentro de los algoritmos estudiados, el algoritmo que se adapta idealmente a este caso es GMRes.

- **[12 puntos]** Ahora, recordemos que lo que se debe resolver es el sistema $A^l \mathbf{x} = \mathbf{b}$, por lo tanto, se necesita un algoritmo que nos permita calcular $A^l \mathbf{v}$ para cualquier $\mathbf{v} \in \mathbb{R}^n$ para luego conectarlo con GMRes, lo cual se puede lograr de la siguiente forma considerando que $l \in \mathbb{N}$:

$$\begin{aligned} A^l \mathbf{v} &= A^{l-1} (A\mathbf{v}) = A^{l-1} \underbrace{(B_1 \mathbf{v} + \text{SFP}(\mathbf{v}))}_{\mathbf{y}_1} = A^{l-2} (A\mathbf{y}_1) \\ &= A^{l-2} \underbrace{(B_1 \mathbf{y}_1 + \text{SFP}(\mathbf{y}_1))}_{\mathbf{y}_2} = A^{l-3} (A\mathbf{y}_2) \\ &= A^{l-3} \underbrace{(B_1 \mathbf{y}_2 + \text{SFP}(\mathbf{y}_2))}_{\mathbf{y}_3} \\ &\vdots \\ &= A \underbrace{(B_1 \mathbf{y}_{l-2} + \text{SFP}(\mathbf{y}_{l-2}))}_{\mathbf{y}_{l-1}} = B_1 \mathbf{y}_{l-1} + \text{SFP}(\mathbf{y}_{l-1}) \end{aligned}$$

Notar entonces que podemos calcular $A^l \mathbf{x}$ como una sucesión de productos matriz-vector, sin necesidad de almacenar de forma explícita la matriz A o la matriz A^l . Un algoritmo para calcular $A^l \mathbf{v}$ tendría la siguiente forma:

- Calcular el vector $\mathbf{y}_1 = B_1 \mathbf{v} + \text{SFP}(\mathbf{v})$.
- Calcular $\mathbf{y}_{k+1} = B_1 \mathbf{y}_k + \text{SFP}(\mathbf{y}_k)$ para k desde 1 hasta $l-1$.

Notar que no es necesario almacenar todos los vectores \mathbf{y}_k , simplemente se puede sobre-escribir en un vector único, digamos \mathbf{y} , pero por claridad de la explicación se presenta como una secuencia de vectores. El procedimiento anterior se puede almacenar en una función, digamos **afun** que recibe el vector \mathbf{v} y retorna el vector $A^l \mathbf{v}$.

- **[6 puntos]** Por lo tanto, podemos utilizar el algoritmo de GMRes para obtener una aproximación $\tilde{\mathbf{x}}$, entregando a GMRes **afun** que obtiene $A^l \mathbf{v}$, el lado derecho \mathbf{b} , un *initial guess* \mathbf{x}_0 y una tolerancia δ , de tal forma que el algoritmo entrega la aproximación $\tilde{\mathbf{x}}$ asegurando que $\|\mathbf{b} - A\tilde{\mathbf{x}}\| \leq \delta$.

```

(b) '''
input:
n      : (integer) dimension of the problem.
l      : (integer) Integer value of l.
B_1    : (ndarray) Sparse matrix B_1. Notice this is defined for simplicity as ndarray.
SFP    : (callable) Procedure that receives the vector 'v' and
computes the 'fast' product between B_2 and the vector 'v'.
b      : (ndarray) Right-hand-side vector.
delta  : (double) Numerical threshold for computation of residual.

output:
xt      : (ndarray) Array with the values of the numerical approximation x_tilde.
'''

def find_x(n,l,B_1,SFP,b,delta):
    ■ [10 puntos] Calcular  $A\mathbf{v}$  para algún vector  $\mathbf{v}$ .
    afun1 = lambda v: np.dot(B_1,v) + SFP(v)
    ■ [10 puntos] Calcular  $A^l\mathbf{v}$  para algún vector  $\mathbf{v} \in \mathbb{R}^n$ 
    def afun2(v):
        y = afun1(v)
        for i in np.arange(l-1):
            y = afun1(y)
        return y
    ■ [5 puntos] Definir el initial guess, utilizar GMRes y retornar la aproximación numérica xt.
    x0 = np.zeros(n)
    xt = GMRes_matrix_free(afun2,b,x0,delta)
    return xt

```